医疗问诊 Agent 的可信验证

从安全规约到运行时保障

让安全要求可表达
让执行行为可检查

面向本科生的形式化方法专题课

应用边界：问诊辅助、风险分流与人工转接

$$M \models \Phi$$

模型

满足

规约

规约 SPECIFY

验证 VERIFY

保障 ENFORCE

今天回答三个问题

一条闭环：问题 → 模型 → 规约 → 反例 → 执行证据

01

验证什么？

把开放式语言行为
分解为可检查的协议
识别输入与环境假设

02

如何验证？

状态机与时序性质
模型检测发现反例
运行时检查实际动作

03

保证到哪里？

区分证据强度
审视真实研究原型
设计医疗评测闭环

学习目标：说清“验证什么、如何验证、保证到哪里”。

发出转接请求，等于完成转接吗？

教学虚构情境：系统已经建立高风险标记，需要进入规定的升级流程。

Agent “我会为您发起人工转接。”

工具 返回：超时，未收到确认。

Agent “已联系医生，本次问诊结束。”

请找出两个协议错误

① 把“请求已发出”
当成“转接已完成”

② 未处理风险仍存在
却允许常规结束

错误位于状态与执行之间： request ≠ acknowledgement ≠ resolution 。

医学证据本身，也有可信边界

从图像处理与多模态诊疗材料中，保留与验证假设直接相关的三个问题。

01

证据要对应

同一患者与正确时间点

影像、报告、陈述需对齐

02

数据会变化

不同医院与设备有域偏移

原有性能不能直接外推

03

解释需审查

关注区域或文字理由

不自动证明医学结论

医学评测负责输入与判断质量；协议验证负责在这些前提下约束行动。

形式化协议依赖输入；证据错误不能由流程正确性自动消除。

参考： [A] 医学图像教学材料； [B] 罗烨：多模态与泛化

验证对象：把 Agent 拆成可分析的系统

开放式语义与有限协议相连接，避免笼统地“验证整个大模型”。



医学评测：事实提取、风险判断与证据质量

形式化验证＋运行时检查

首选验证对象：状态迁移、动作权限、故障分支与结束条件。

一个可信主张，必须写出条件

将“系统很安全”改写成可审查、可证伪的条件性主张。

系统与满足假设的环境共同满足规约： $M /\!/ E_A \models \phi$

对象 M

有限状态的问诊控制流程

工具接口与故障分支

性质 φ

未授权不披露

未处理风险不常规结束

假设 A

风险事件与日志可靠

工具语义、调度条件明确

结论要附带模型范围与接口假设；未知状态必须有明确处理。

最小状态机：为失败保留一条路

状态：风险待处理、请求中、已转接、安全回退；事件：确认、失败、超时。



risk_pending 只能在完成规定处理后清除；“普通结束”需要独立守卫。

LTL：把“不能做”与“必须做”分开

G：始终； F：最终。原子命题来自结构化状态与事件，而非模糊的文本评分。

类型	示例规约	解释
安全性	G(disclose → consent_valid)	每次受保护披露都有有效授权
安全性	G(risk_pending → ¬routine_close)	未处理风险阻止常规结束
活性	G(risk_pending → F resolved)	最终完成转接或规定回退

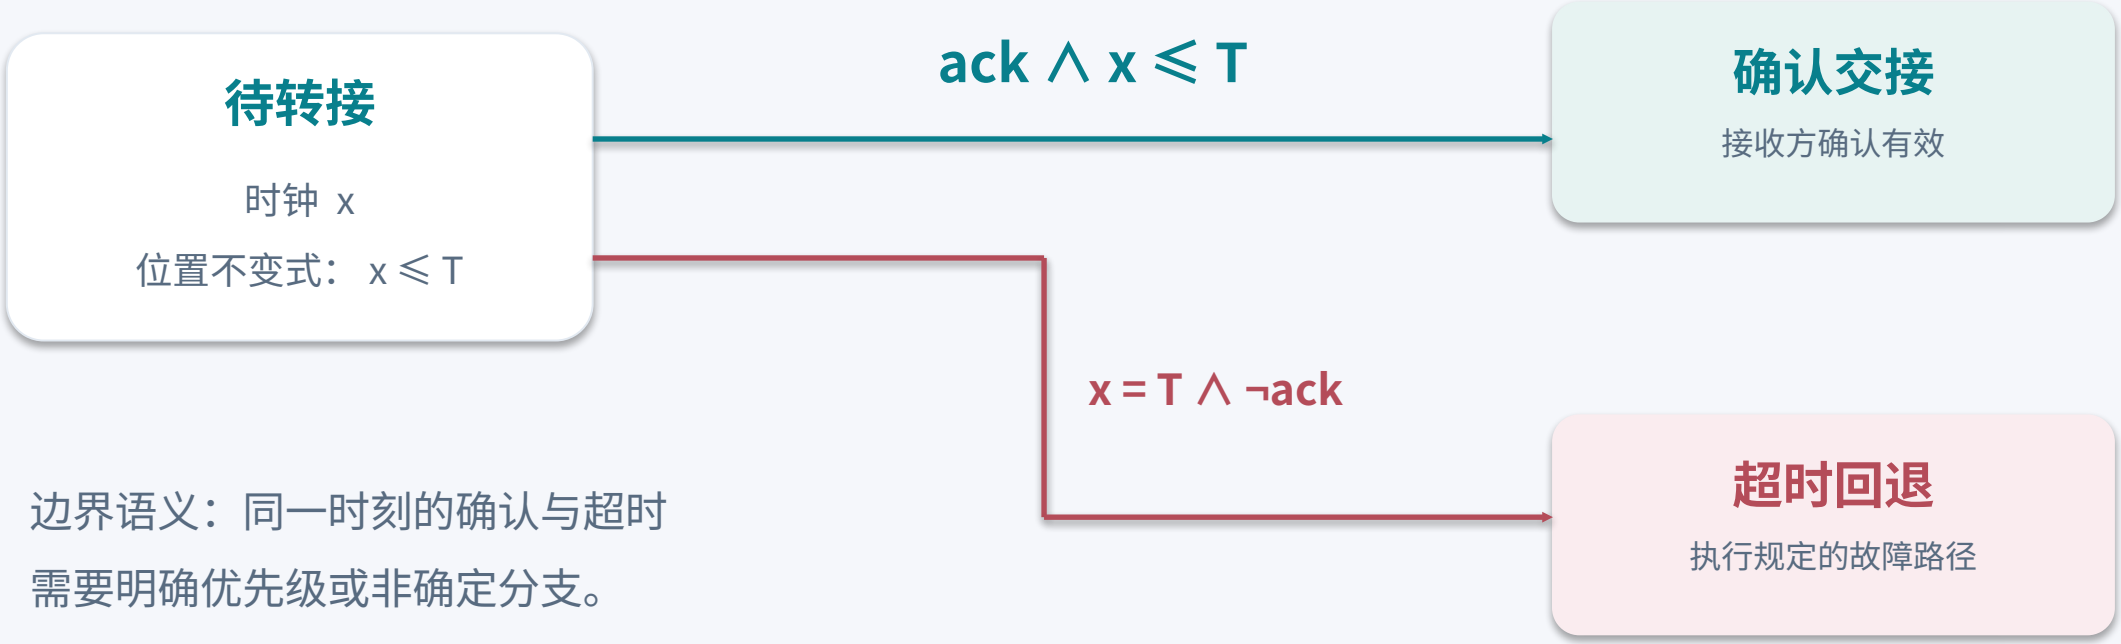
有限前缀可暴露安全违例；仅观察“尚未完成”，通常不能判定无界活性已经违反。

活性需环境假设； resolved 的定义不能只写“已发出请求”。

参考：[1] SPIN / Holzmann, 1997

时间自动机：让“最终”具有期限

进入等待状态时 x := 0；期限 T 由经过审查的临床／服务协议确定。



边界语义：同一时刻的确认与超时需要明确优先级或非确定分支。

同时检查时间可推进与无死锁，避免靠阻塞时间获得“表面通过”。

参考：[2] 时间自动机 / Alur & Dill, 1994；[3] UPPAAL / Behrmann et al., 2004

模型检测：把担忧变成一条反例

检查模型中所有允许的行为；抽象反例需要回放，必要时精化。

系统模型 M

状态 / 转移 / 故障

规约 φ

安全 / 活性 / 时限

检查结果

满足或反例轨迹

反例：状态被错误更新，导致未处理风险被关闭

发现风险 → 发起请求 → 接口失败 → 误清 pending → 常规结束

模型层通过 ≠ 实现层通过；真实行为与抽象之间仍需建立对应。

参考：[1] SPIN / Holzmann, 1997；[3] UPPAAL / Behrmann et al., 2004

运行时保障：验证结果必须进入执行链

控制所有受保护动作的入口；状态、授权和反馈必须使用可信数据源。



允许 满足策略 → 执行

拒绝 违反策略 → 阻止

待定 状态不足 → 澄清 / 人工

前置检查阻止违规动作；事后监控记录偏差；两者不能互相替代。

参考：[4] VeriGuard, 2025

已有实践：先辨别证据，再评价“可信”

公开实践已经存在，但不同工作验证的对象与证据强度不同。

工作	验证／评测对象	已有证据	关键边界
GCAC · 2026*	照护协调与结果闭环	18 条契约轨迹	模拟工具；非全路径证明
SDC–MCP · 2026*	医疗设备接口执行边界	只读 / dry-run 原型	无设备写操作；非临床部署
VeriGuard · 2025*	Agent 策略代码	Nagini/Viper 验证	通用方法；非问诊系统
AgentClinic · 2024–	临床连续交互	模拟环境实验	经验评测；非形式化证明
MedAgentBench · 2025	虚拟 EHR 任务执行	300 任务 / FHIR 环境	任务结果；非全流程保证

* 本页引用预印本；资料核对截至 2026-10-14 。医疗问诊全过程的成熟形式化保证，本次检索未确认。

测试、契约检查、程序证明与临床验证，不能用同一个“已验证”概括。

参考：[4] VeriGuard, 2025；[5] GCAC, 2026 · 预印本；[6] SDC–MCP Gateway, 2026 · 预印本；[7] AgentClinic, 2024–；[8] MedAgentBench, 2025

GCAC： 任务结束必须有结果证据

居家痴呆照护：用药设备“未记录一次服药”，并不等于临床确认漏服。

已实现的参考框架

提议 读取有来源、有版本的记忆

授权 确定性策略检查角色与权限

闭环 确认、回退与未完成义务追踪

作者报告：需求导出的轨迹测试

18 / 18

满足契约检查

测试中零违规工具调用

确定性 Python 框架＋模拟工具

18/18 说明有限测试套件中的契约一致性；不说明真实患者获益或所有路径安全。

参考：[5] GCAC, 2026 · 预印本

研究闭环：验证正确性，也评估使用代价

拟开展研究；目前没有自有医疗 Agent 实现或实验结果。

组别	安全机制	回答的研究问题
A	基础 Agent	无机制时的失败模式
B	提示词约束	文本提醒是否有效
C	人工规则网关	增加规则带来的收益
D	验证协议＋执行监控	验证与一致性是否增益

场景覆盖：证据冲突、权限变化、工具失败、超时、旧状态。

三组证据一起报告

安全：漏升级 / 违规轨迹

代价：误拦截 / 延迟

对应：反例回放 / 状态误差

固定模型、工具与预算

病例分层＋置信区间

目标：降低违规，同时明确误拦截、过度升级与延迟的代价。

参考：[7] AgentClinic, 2024–；[8] MedAgentBench, 2025

可信来自证据链，而非一个分数

明确对象与假设；用规约约束行为；在运行中核对结果。

医学证据

事实与风险是否可靠?

形式化规约

允许什么，禁止什么?

验证与保障

模型、实现、执行是否对应?

我们能验证明确协议中的明确性质；医学理解与真实临床效果仍需独立证据。

下一步：专家共建规约 → 最小原型 → 反例回放 → 独立医疗评测。

参考：[1] SPIN / Holzmann, 1997；[3] UPPAAL / Behrmann et al., 2004；[5] GCAC, 2026 · 预印本；[6] SDC-MCP Gateway, 2026 · 预印本